Проектная работа · Большие данные

Study RAG

Мультиагентная разметка учебных материалов и поиск по ним с ответами со ссылками на источник

Никулин Д.Э., Тугулева К.С. · группа 4307
Руководитель: Мокшин В.В.

study-rag-livid.vercel.app · вход «Войти как проверяющий»

Материалы есть, но искать по ним нельзя

572

документа КИ за I–V семестры

41 %

без предмета

≈248

с титульными листами: чужие ФИО, группы

5 014

картинок без описаний

- Тип документа ставился по умолчанию: «задание» у 244, «другое» у 131
- Без меток нет фильтров «предмет», «преподаватель», «семестр»
- Чат-бот общего назначения отвечает без ссылки на слайд

Идея

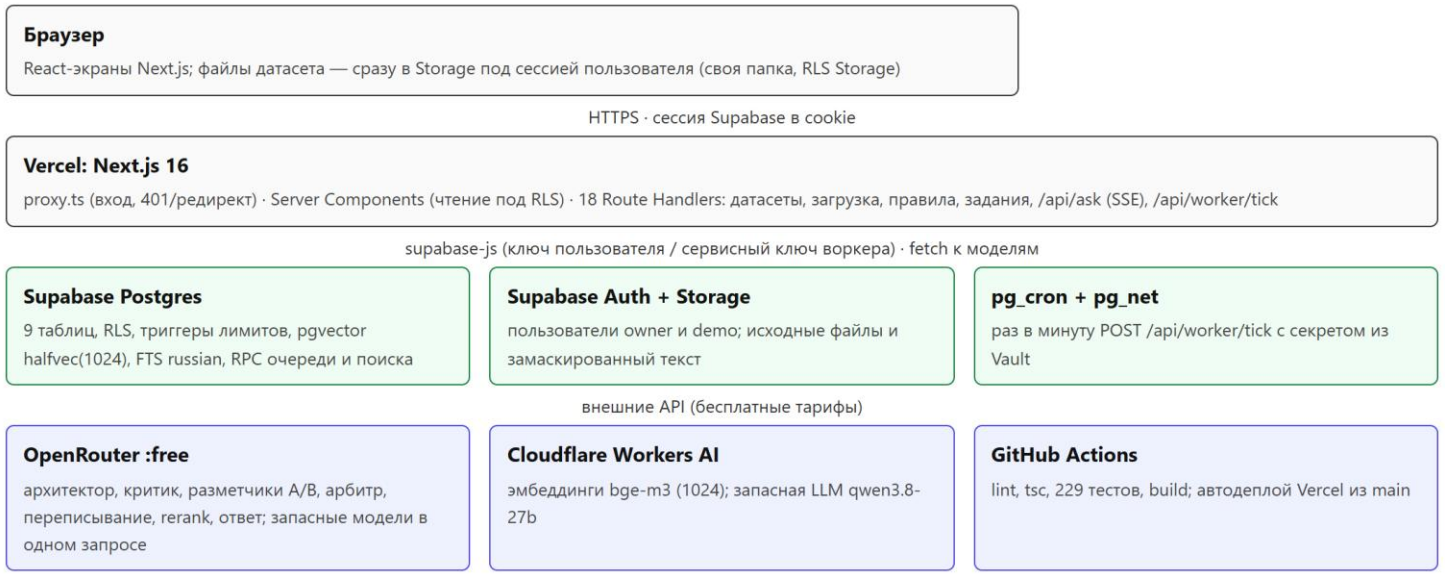
Разметку делает приложение: агенты предлагают правила и размечают, человек утверждает и разбирает сомнительное. По размеченному корпусу работает RAG.

Конвейер: от загрузки до ответа со сносками



Схема полей не зашита в код: её предлагает агент под конкретный набор, поэтому конвейер подходит для любых документов

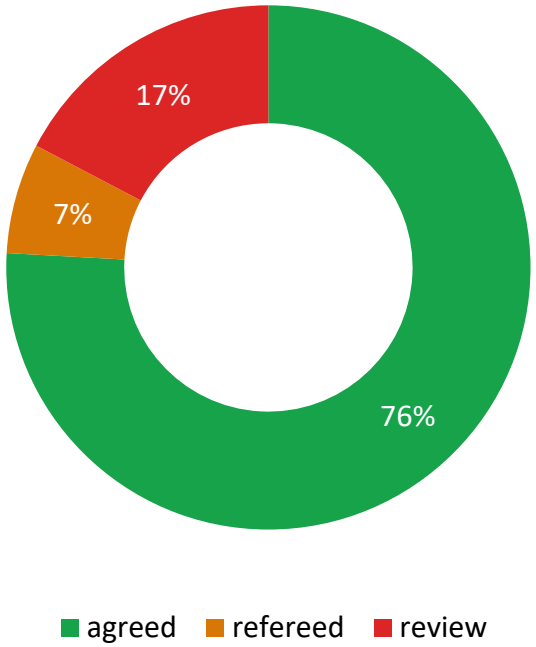
Архитектура на бесплатных тарифах



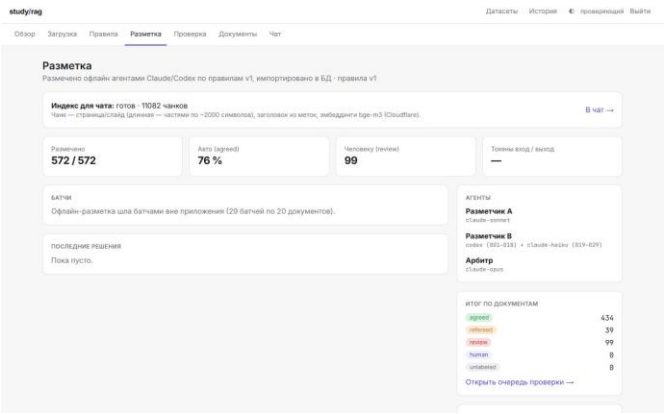
- Next.js 16 на Vercel: экраны и 18 API-маршрутов
- Supabase: 9 таблиц, RLS, pgvector, FTS russian
- Очередь в Postgres; pg_cron раз в минуту будит воркер, если есть работа
- LLM — бесплатные модели OpenRouter, запасная — Cloudflare
- Сервисы и модели приложения — 0 ₽ (офлайн-разметка — по имеющейся подписке)

Двое разметчиков, арбитр и очередь человеку

572 документа после разметки



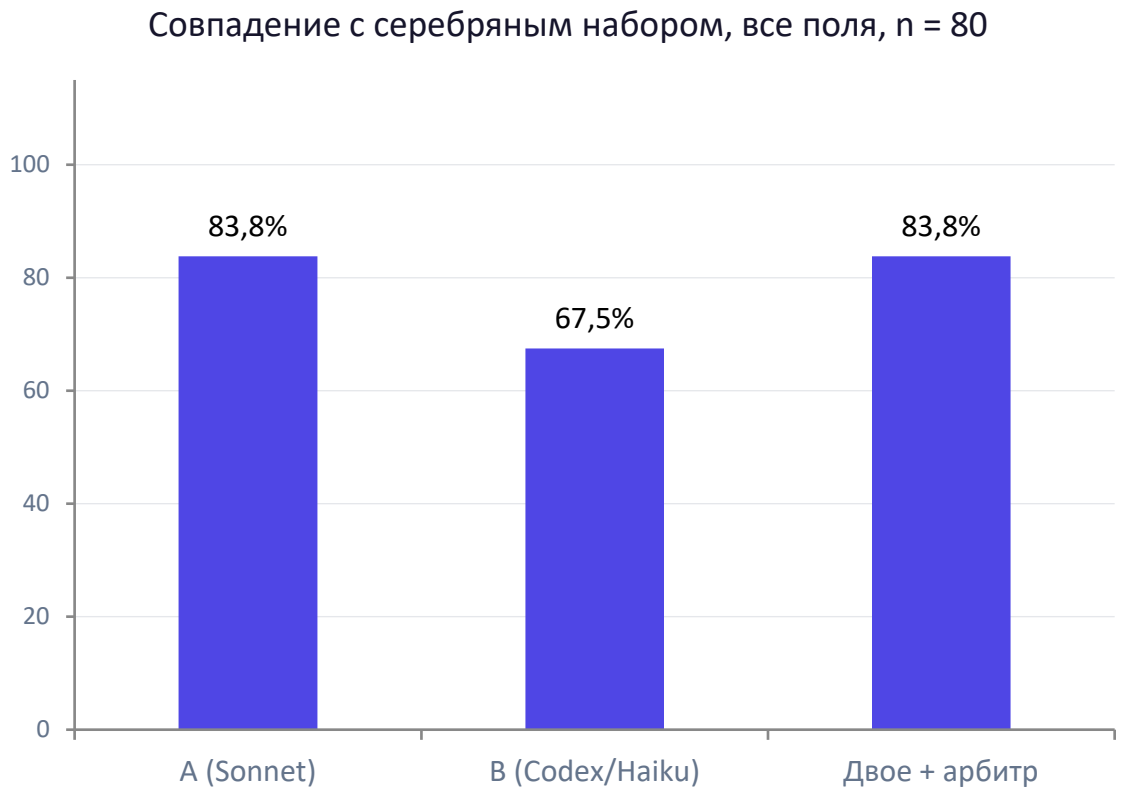
- Правила v1: архитектор по 30 документам, критик по другим 20 — 16 правок
- A — Claude Sonnet, B — Codex и Claude Haiku, арбитр — Claude Opus
- Каппа Коэна A/B по полям: 0,907–0,965 (A и Haiku — одно семейство, согласие завышено)
- Арбитр уверенно решил 39 из 69 споров, остальное — человеку

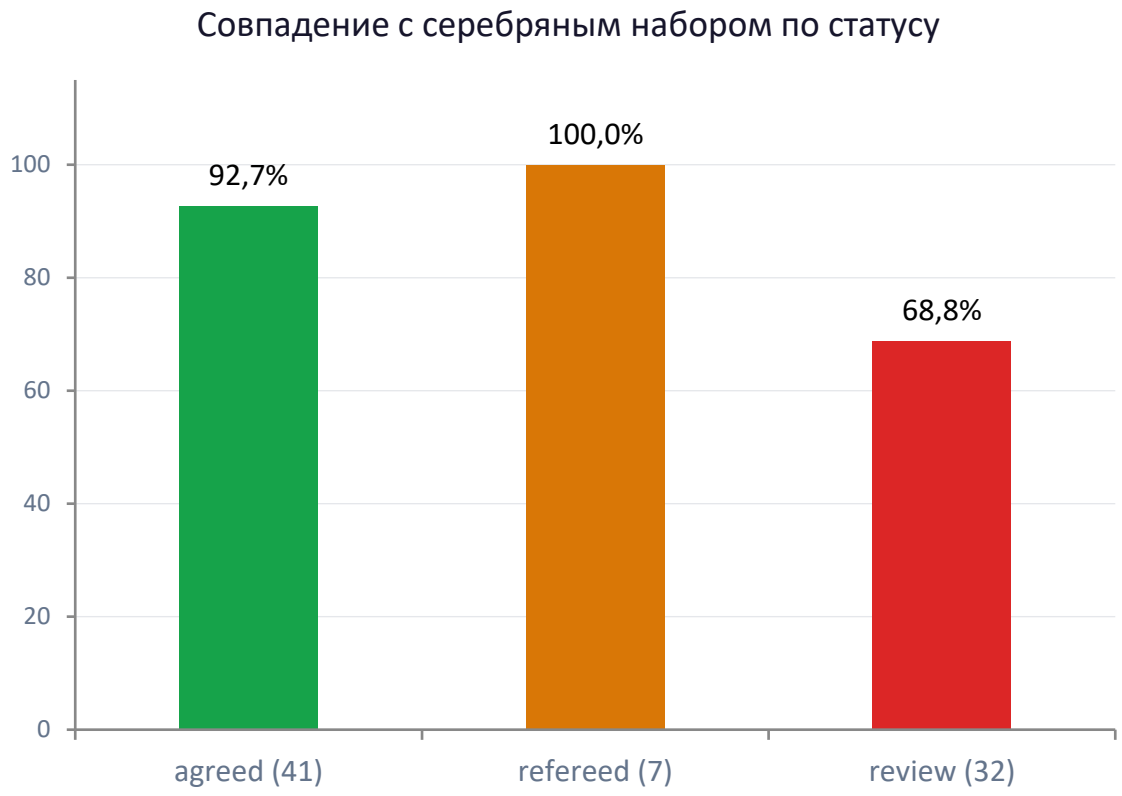


Доска разметки на проде

Основной датасет размечен агентами офлайн (50 бесплатных запросов в день не хватает); в приложении весь путь проверен на 8 документах: 192 с, $0

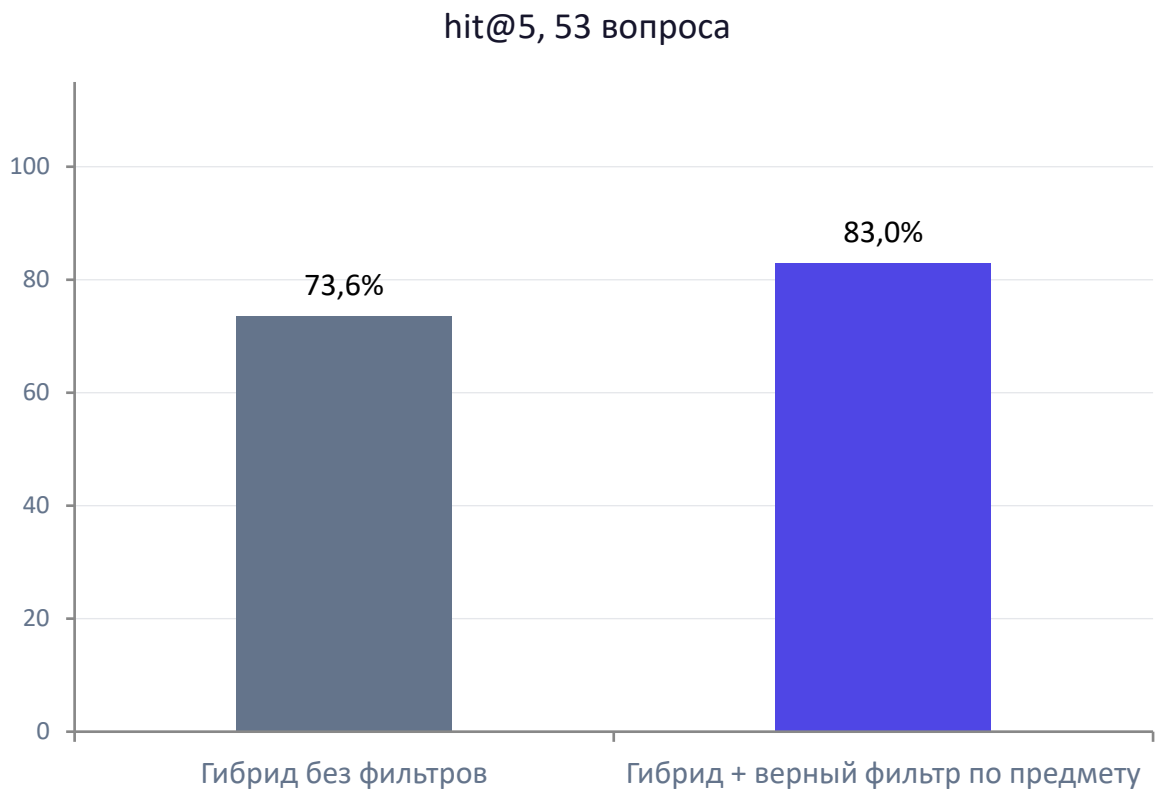
Схема не точнее лучшего разметчика, но сортирует





Эталон — разметка Claude Opus, не людей (с 19 ручными проверками совпадает на 36,8 %). Выборка 80 не случайная: 43 документа — с низкой уверенностью. review: 10 расхождений из 32, agreed: 3 из 41.

Верный фильтр из разметки: hit@5 83 % вместо 74 %



+9,4

п. п. hit@5 от фильтра (5 вопросов из 53)

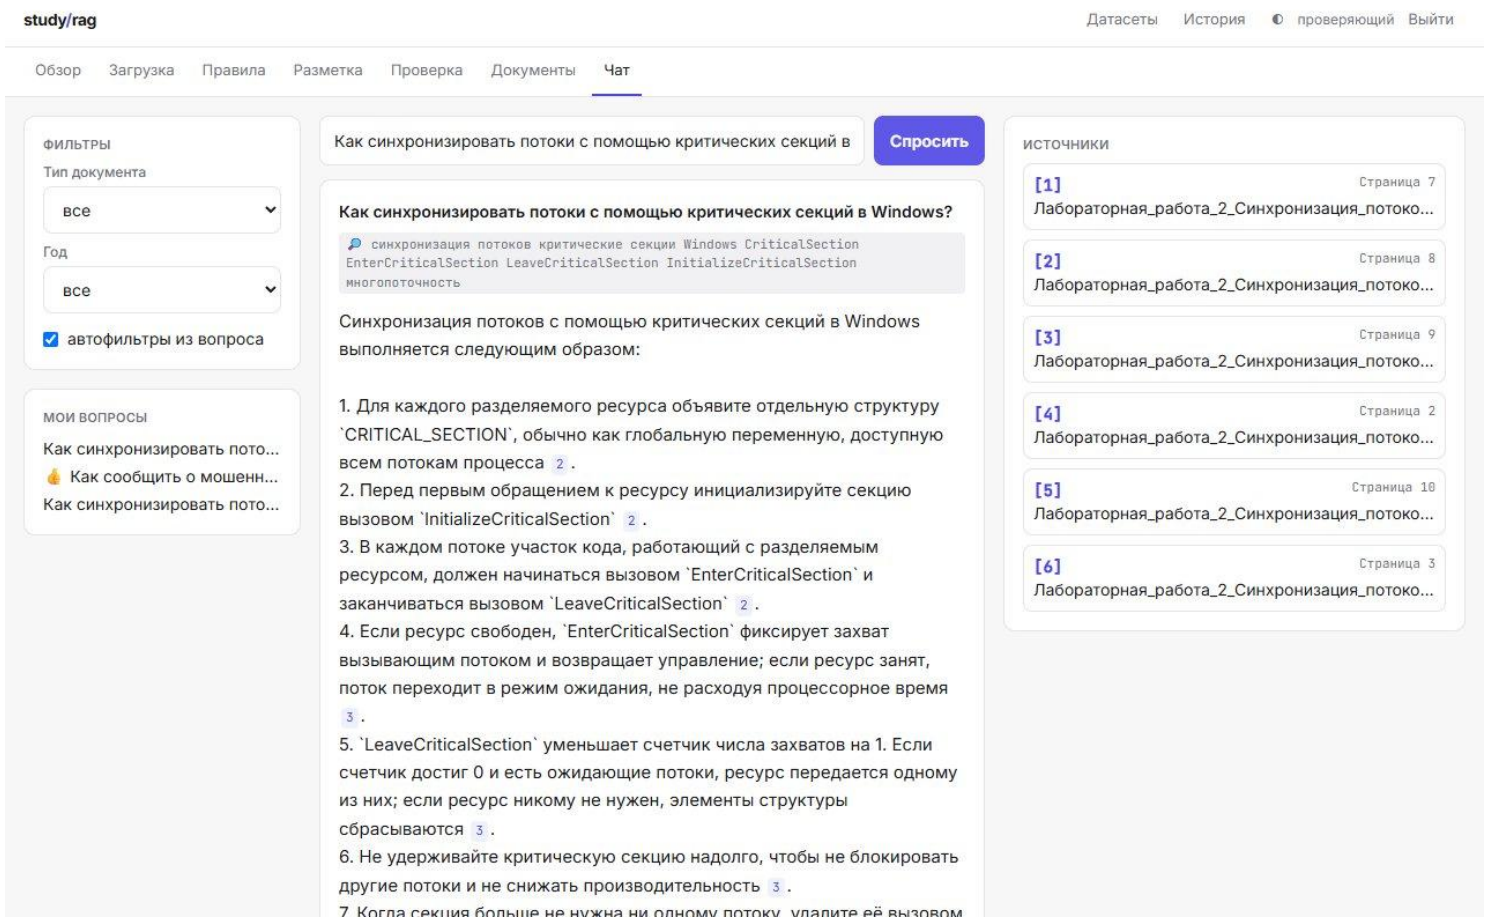
−10

п. п. hit@5 от rerank (2 вопроса из 20)

- MRR@10: 0,544 → 0,630
- Пустая выдача после rerank на вопросах без ответа: 6 из 8
- Ложные отказы: 2 из 20

Фильтр взят из разметки вопроса (заранее верный), запрос не переписывался; интервал для 83 % — 71–91 %. Вопросы сгенерированы моделью. Путь с rerank — 70 % на 20 вопросах.

Демо: вопрос → ответ со сносками



Чат тестового датасета; основной тоже отвечает — поиск 0,45 с (миграция 9)

- Вход «Войти как проверяющий»
- Обзор датасета: 572 документа, ПДн замаскированы в 410 (не только титульники)
- Правила v1 и доска разметки
- Очередь проверки: голоса A и B с цитатами
- Чат: переписанный запрос, сноски [n], источник со страницей

Как делали: ИИ-агенты и проверки

229

автотестов, из них 27 SQL/RLS

16

дефектов нашёл финальный критик загрузки

11

экранов, мобильная и тёмная тема

0 ₽

на сервисы и модели приложения

- Claude Code писал код; субагенты — разметчики, арбитры, критики
- TDD с двумя независимыми критиками для загрузки и разметки
- Каждая цифра отчёта сверяется с таблицей (ловили «21 вопрос» вместо 1)

Text-to-UI в v0

Экраны чата и доски по текстовому описанию: 15 файлов, раскладка по нашему дизайну, но ответ — заглушка 501. Ветка не слита.

Итоги

- Работает: загрузка с маскированием ПДн → правила агентов → разметка «двое + арбитр + человек» → RAG со сносками
- Разметка помогает поиску: с верным фильтром по предмету hit@5 83,0 % против 73,6 % без
- Человеку — 17 % корпуса; там в ~4 раза больше расхождений с серебряным набором
- Ограничения: серебряный набор — модель, вопросы сгенерированы, фильтр в оценке задан заранее, rerank ухудшил выдачу, ответ бесплатной моделью — до 100 с
- Дальше: правила v2, ручная проверка очереди, настоящие вопросы студентов

study-rag-livid.vercel.app · github.com/fA1N-n/study-rag