Проектная работа · Большие данные

Study RAG

Мультиагентная разметка учебных материалов и поиск по ним с ответами со ссылками на источник

Никулин Д.Э., Тугулева К.С. · группа 4307
Руководитель: Мокшин В.В.

study-rag-livid.vercel.app · вход «Войти как проверяющий»

Материалы есть, но искать по ним нельзя

572

документа КИ за I–V семестры

41 %

без предмета

≈248

с чужими ФИО и группами

5 014

картинок без описаний

- Тип документа ставился по умолчанию: «задание» у 244, «другое» у 131
- Без меток нет фильтров «предмет», «преподаватель», «семестр»
- Чат-бот общего назначения отвечает без ссылки на слайд

Идея

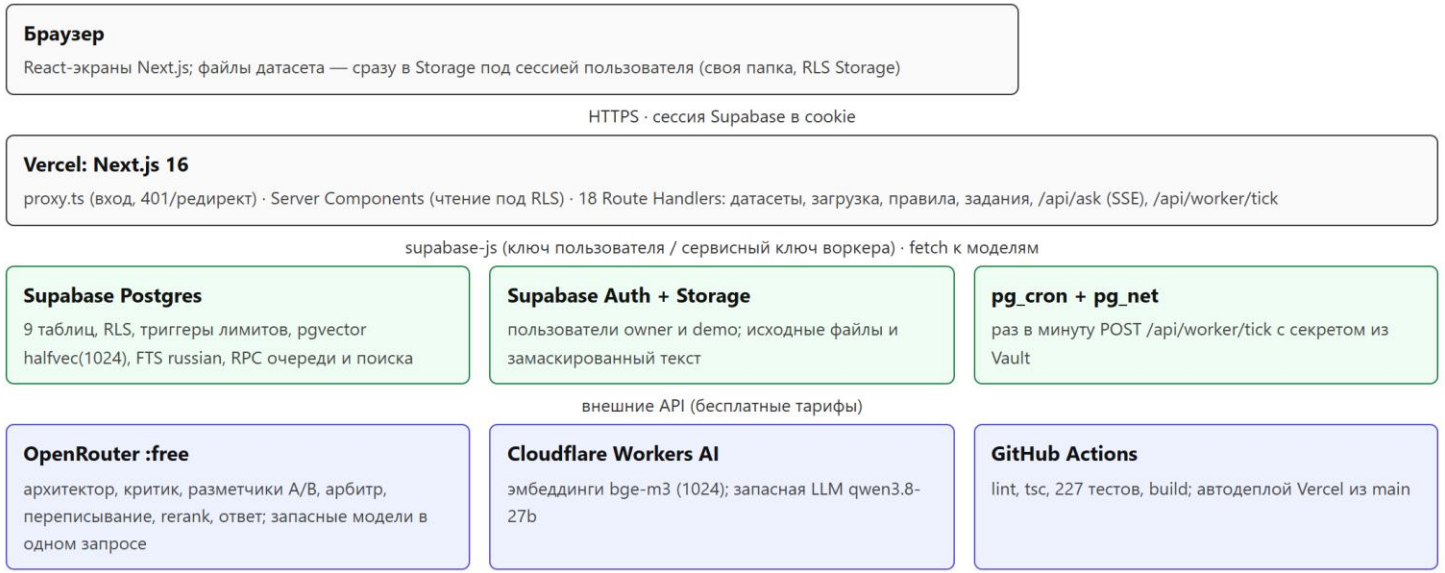
Разметку делает приложение: агенты предлагают правила и размечают, человек утверждает и разбирает сомнительное. По размеченному корпусу работает RAG.

Конвейер: от загрузки до ответа со сносками



Схема полей не зашита в код: её предлагает агент под конкретный набор, поэтому конвейер подходит для любых документов

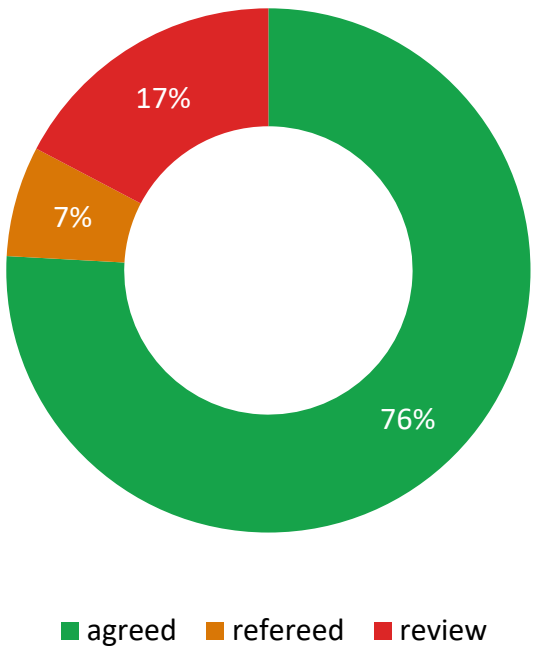
Архитектура на бесплатных тарифах



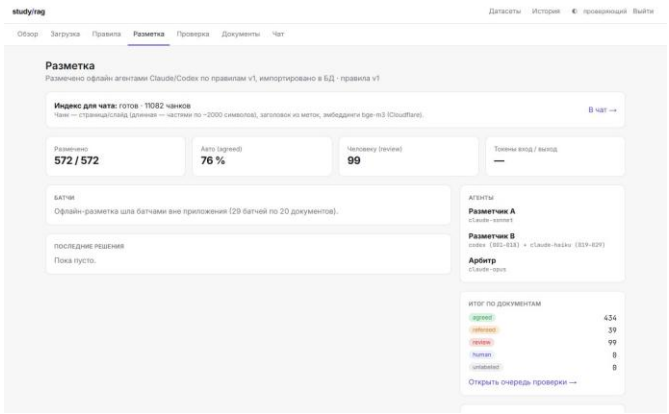
- Next.js 16 на Vercel: экраны и 18 API-маршрутов
- Supabase: 9 таблиц, RLS, pgvector, FTS russian
- Очередь в Postgres, pg_cron раз в минуту дёргает воркер
- LLM — бесплатные модели OpenRouter, запасная — Cloudflare
- Затраты на сервисы и модели — 0 ₽

Двое разметчиков, арбитр и человек

572 документа после разметки



- Правила v1: архитектор по 30 документам, критик по другим 20 — 16 правок
- A — Claude Sonnet, B — Codex и Claude Haiku, арбитр — Claude Opus
- Каппа Коэна A/B по полям: 0,907–0,965
- Арбитр уверенно решил 39 из 69 споров, остальное — человеку

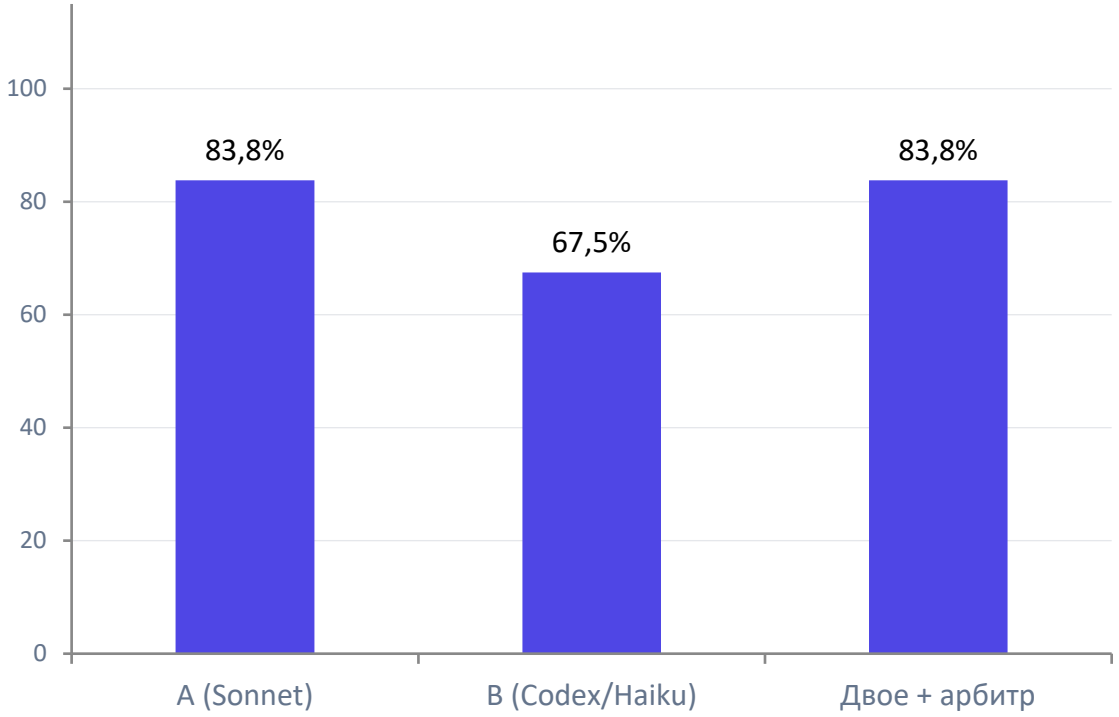


Доска разметки на проде

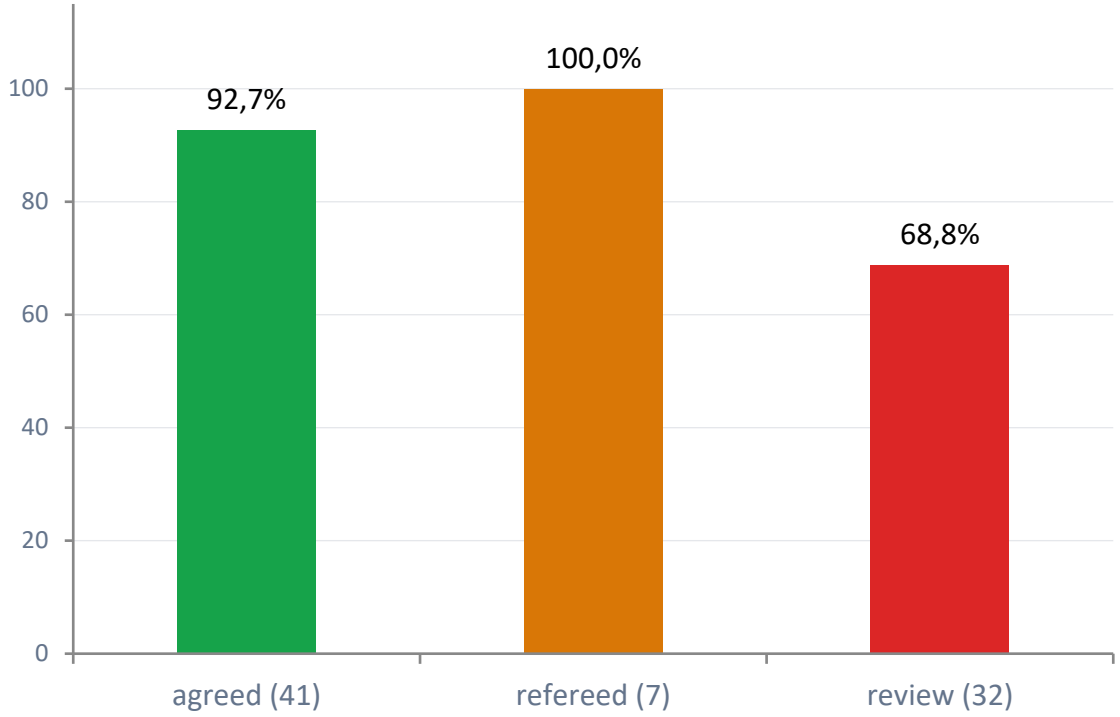
Основной датасет размечен агентами офлайн (50 бесплатных запросов в день не хватает); в приложении весь путь проверен на 8 документах: 192 с, $0

Схема не точнее лучшего разметчика, но сортирует

Совпадение с серебряным набором, все поля, n = 80

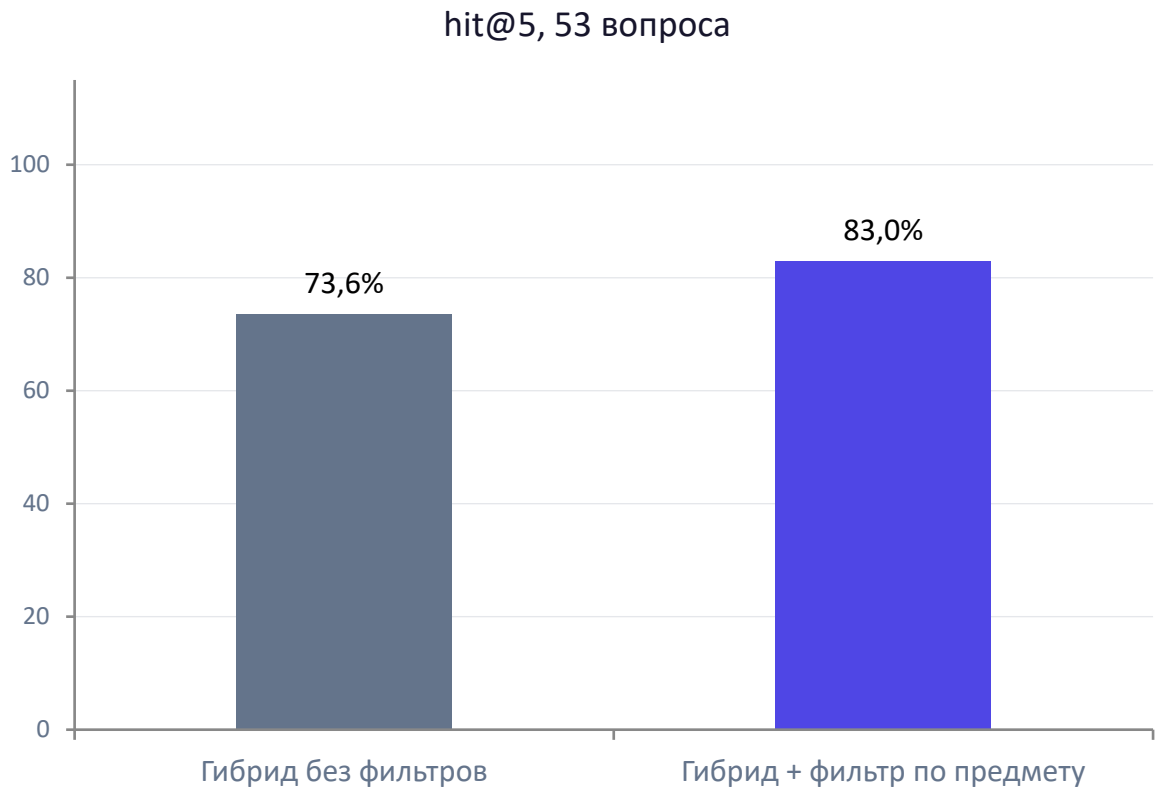


Точность по статусу маршрутизации



Серебряный набор — разметка Claude Opus по полному тексту, не людьми; с 19 ручными проверками он совпадает на 36,8 % по документу целиком. Интервал Уилсона для A и итога — 74–90 %.

Фильтр из разметки вывел поиск на цель 0,8



+9,4

п. п. hit@5 от фильтра по предмету

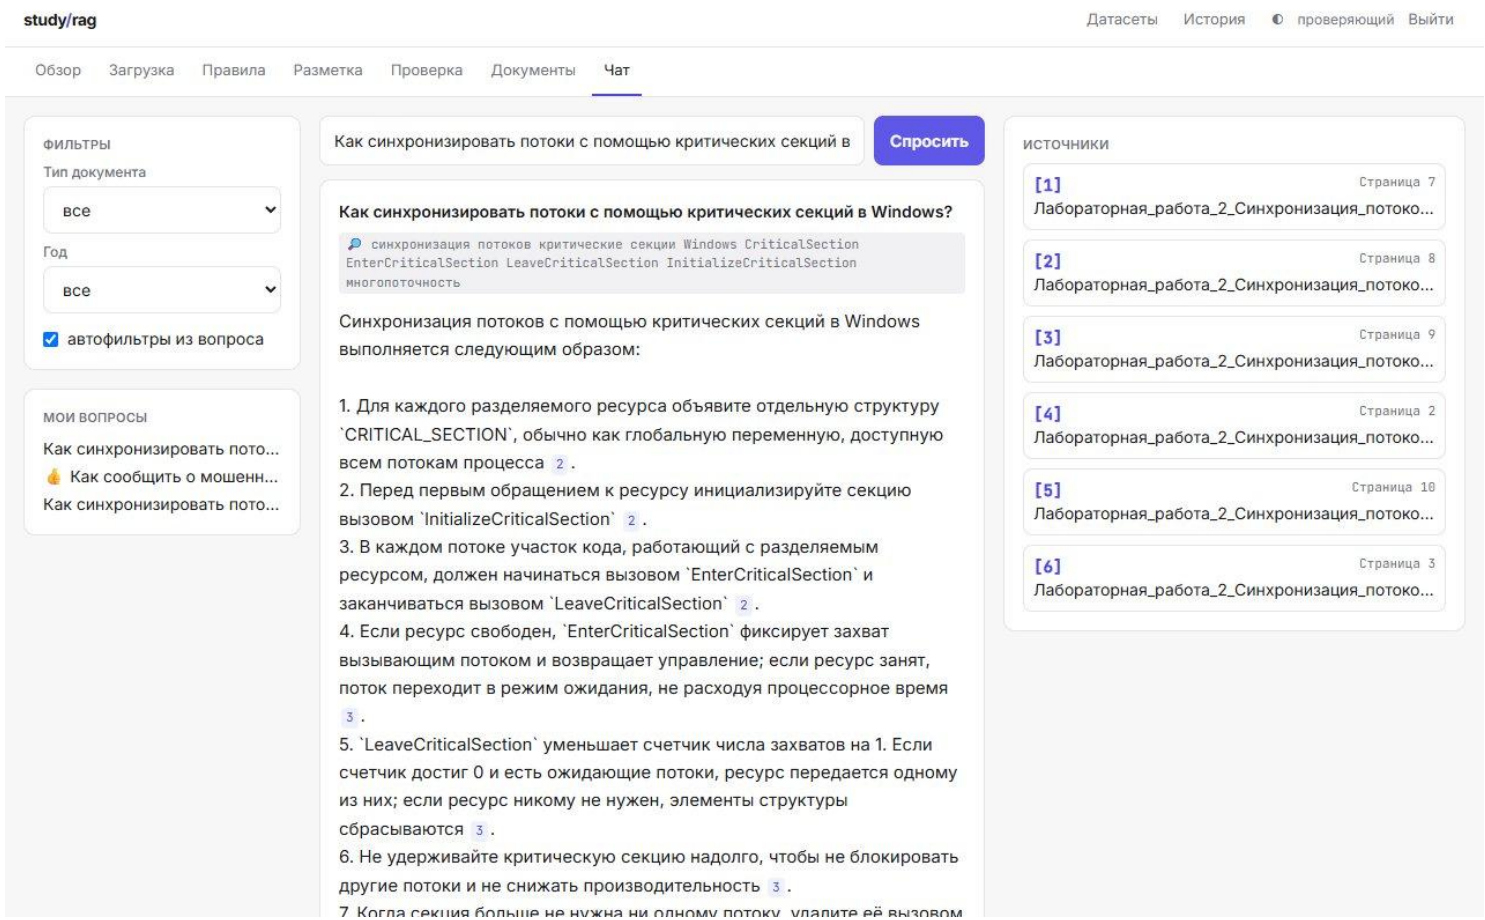
−10

п. п. hit@5 от rerank бесплатной LLM (n = 20)

- MRR@10: 0,544 → 0,630
- Отказ на вопросах без ответа: 6 из 8
- Ложные отказы: 2 из 20

Вопросы сгенерированы моделью, настоящих вопросов студентов нет — метрики могут быть завышены. Rerank оставлен ради отказов; дальше — порог 3/10 или модель сильнее.

Демо: вопрос → ответ со сносками



- Вход «Войти как проверяющий»
- Обзор датасета: 572 документа, 410 с замаскированными ПДн
- Правила v1 и доска разметки
- Очередь проверки: голоса A и B с цитатами
- Чат: переписанный запрос, сноски [n], источник со страницей

Как делали: ИИ-агенты и проверки

227

автотестов, из них 25 SQL/RLS

16

дефектов нашёл финальный критик загрузки

11

экранов, мобильная и тёмная тема

0 ₽

на сервисы и модели

- Claude Code писал код; субагенты — разметчики, арбитры, критики
- TDD с двумя независимыми критиками для загрузки и разметки
- Каждая цифра отчёта сверяется с таблицей (ловили «21 вопрос» вместо 1)

Text-to-UI в v0

Экраны чата и доски по текстовому описанию: 15 файлов, раскладка по нашему дизайну, но ответ — заглушка 501. Ветка не слита.

Итоги

- Работает: загрузка с маскированием ПДн → правила агентов → разметка «двое + арбитр + человек» → RAG со сносками
- Разметка окупилась в поиске: hit@5 83,0 % с фильтром против 73,6 % без
- Человеку — 17 % корпуса, и ошибок там в 4 раза больше
- Ограничения: серебряный набор — модель, вопросы сгенерированы, rerank ухудшил выдачу
- Дальше: правила v2, ручная проверка очереди, настоящие вопросы студентов

study-rag-livid.vercel.app · github.com/fA1N-n/study-rag